Instituto Superior de Contabilidade e Administração do Porto
Mestrado em Business Intelligence and Analytics

Analítica para Big Data

Implementação de um Pipeline de Big Data

Análise de Criminalidade em Chicago

João [Apelido]
junho de 2026

1. Introdução

Chicago disponibiliza publicamente cada ocorrência policial registada no sistema CLEAR da Polícia Municipal — são mais de 8 milhões de registos acumulados desde 2001, actualizados com um asfasamento de sete dias. Para este trabalho, foram recolhidos os dados de 1 de janeiro de 2022 até à data de extração, o que resultou em 1.077.035 ocorrências.

A pergunta de partida não era técnica. Era: o que é que um pipeline de Big Data consegue revelar sobre os padrões de criminalidade de uma cidade desta dimensão? Onde acontecem os crimes? A que horas? Que tipos dominam e como evoluíram nos últimos quatro anos? Responder a isto — com um milhão de registos — exigiu escolhas deliberadas sobre armazenamento, processamento e organização dos dados.

Este relatório descreve o pipeline construído e, sobretudo, o que os dados disseram.

2. O Dataset

Os dados são obtidos via API REST (https://data.cityofchicago.org/resource/ijzp-q8t2.json). A API devolve resultados em JSON com um limite de 50.000 registos por pedido, o que obrigou a implementar paginação com offset incremental durante a ingestão. Cada registo descreve um incidente criminal com dezenas de campos: tipo de crime, data e hora exata, localização geográfica (coordenadas GPS, distrito policial, community area, ward), e dois indicadores operacionais — se resultou em detenção e se foi classificado como crime doméstico.

A distribuição por ano reflete a evolução da criminalidade no período analisado:

Ano	Registos
2022	240.084
2023	263.345
2024	259.129
2025	237.248
2026	77.229 (ano em curso)
Total	1.077.035

Tabela 1 — Volume de registos por ano após limpeza

2023 foi o ano com mais ocorrências. A descida em 2025 é real — não é um artefacto de dados incompletos. O valor de 2026 é naturalmente inferior por se tratar de um ano ainda em curso na data de extração.

3. Arquitetura do Pipeline

O pipeline segue a Medallion Architecture, organizada em três camadas: Bronze (dados brutos), Silver (dados limpos e tipados) e Gold (agregações analíticas). A escolha não foi arbitrária — com um dataset desta dimensão, misturar ingestão, limpeza e análise no mesmo passo tornaria qualquer erro difícil de rastrear e qualquer reprocessamento custoso.

O ambiente foi o JupyterHub disponibilizado pelo professor, com HDFS no endereço hdfs://hadoop-master:39000 como sistema de armazenamento distribuído. Os scripts de processamento foram executados via spark-submit no terminal Linux integrado.

3.1 Bronze — os dados como chegaram

A Bronze Layer guarda os dados exactamente como a API os devolveu, em formato JSON Lines (um registo por linha), particionados por ano em pastas no estilo Hive (year=2022, year=2023, etc.). Não há qualquer transformação nesta fase — o objetivo é ter um repositório imutável que permita reprocessar tudo a partir do zero se necessário.

A ingestão foi feita por um script Python (ingest_bronze.py) com paginação automática e retry com cinco tentativas por pedido — necessário porque a API apresentou timeouts em algumas execuções durante o desenvolvimento. No final da ingestão, os ficheiros foram enviados para o HDFS com hdfs dfs -put.

3.2 Silver — limpeza e enriquecimento

A Silver Layer leu todos os ficheiros JSON do Bronze com o Spark e aplicou um conjunto de transformações: seleção das colunas relevantes (de mais de vinte campos originais ficaram dezasseis), renomeação para nomes mais descritivos, conversão de tipos (todos os campos chegam como string da API), e criação de três colunas derivadas a partir da data do crime — o mês, a hora e o dia da semana. Estas colunas evitam recomputações em cada análise posterior.

O tratamento de nulos merece nota. O campo location_description tinha 5.236 valores em falta — foi preenchido com "UNKNOWN" para não perder registos completos nas restantes dimensões. Para latitude, longitude, ward e community_area (essenciais para as análises geográficas), a opção foi eliminar a linha. No total foram removidos cerca de 10.500 registos, menos de 1% do volume total.

O resultado foi guardado em formato Parquet com compressão Snappy, particionado por ano. Parquet lê apenas as colunas necessárias para cada operação, tem compressão integrada e guarda o schema de forma nativa — a diferença de desempenho face a JSON para leituras analíticas é significativa.

3.3 Gold — métricas prontas a usar

A Gold Layer calculou 15 agregações a partir do Silver, cada uma guardada em pasta separada no HDFS. O volume colapsa de um milhão de linhas individuais para tabelas com dezenas ou centenas de linhas — as consultas tornam-se praticamente instantâneas.

As métricas cobrem cinco eixos de análise: temporal (por hora, dia da semana, mês, período do dia), geográfico (por distrito, community area, ward), tipológico (top crimes, evolução por tipo), operacional (taxa de detenções por tipo e por distrito) e cruzamentos multidimensionais (tipo de crime por hora do dia).

A estrutura no HDFS ficou organizada sob o directório // com as subpastas bronze/, silver/ e gold/, cada uma com as respectivas partições por ano.

4. Análise dos Resultados

Os resultados são apresentados agrupados por tema analítico, não pela ordem em que os gráficos foram gerados. A ideia é que cada secção responda a uma pergunta concreta sobre a criminalidade em Chicago.

4.1 Evolução global: 2023 foi o pico, 2025 já desceu

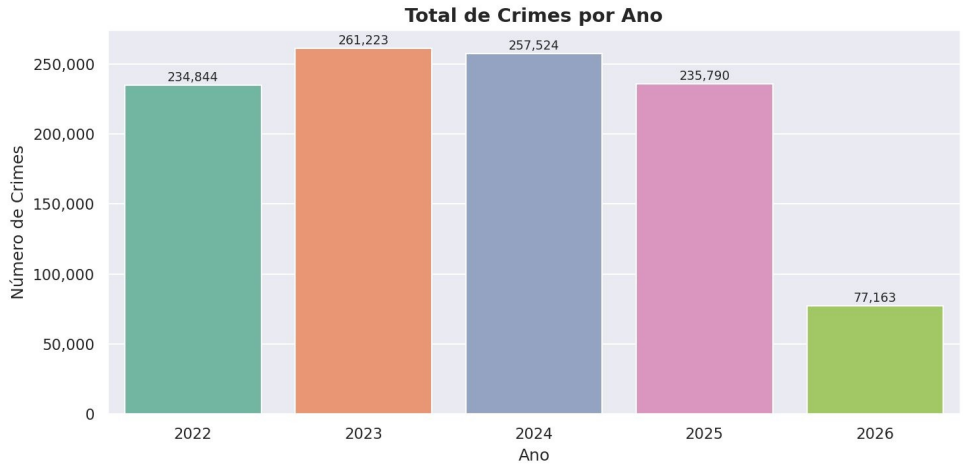


Figura 1 — Total de crimes por ano (2022–2026)

O total de crimes atingiu o máximo em 2023 (261.223), com uma ligeira descida em 2024 (257.524) e uma descida mais acentuada em 2025 (235.790), que já fica abaixo dos valores de 2022. É cedo para dizer se é uma tendência estrutural ou variação normal, mas a descida de 2025 é real — não é explicada por dados incompletos.

4.2 A criminalidade tem horário — e é diurna

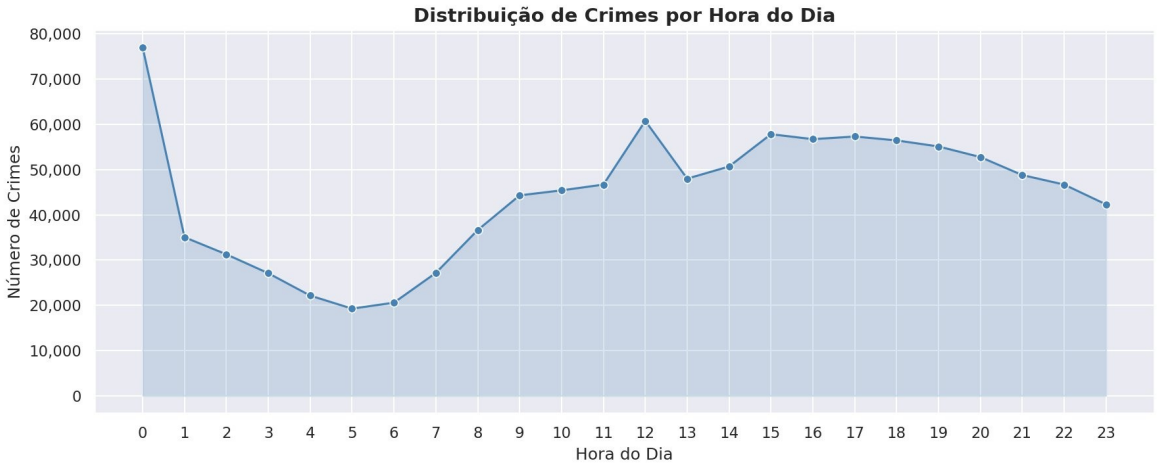


Figura 2 — Distribuição de crimes por hora do dia

O padrão por hora do dia é claro: existe um pico elevado à meia-noite (hora 0) — provavelmente relacionado com o registo automático de ocorrências sem hora precisa — depois uma queda acentuada até às 5h da manhã, e a seguir uma subida progressiva com um segundo pico ao meio-dia. A criminalidade mantém-se elevada durante toda a tarde.

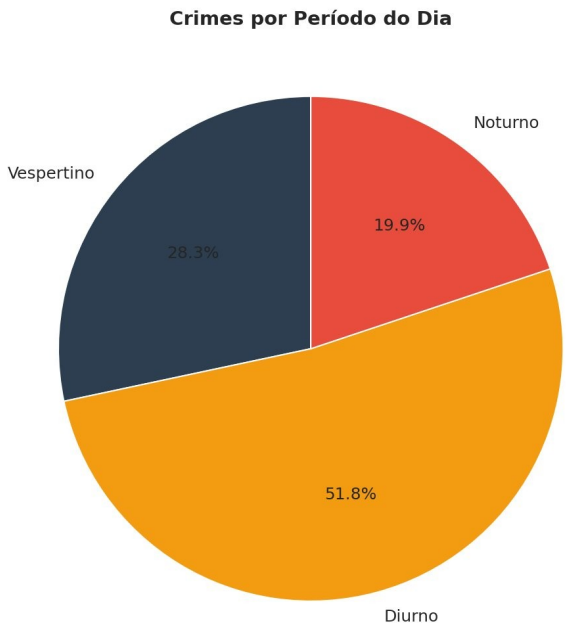


Figura 3 — Crimes por período do dia

Agrupando por período, mais de metade dos crimes (51,8%) ocorre durante o período diurno (6h–18h). O período vespertino (18h–00h) representa 28,3% e o noturno (00h–06h) apenas 19,9%. A ideia de que os crimes acontecem maioritariamente à noite não se confirma neste dataset — pelo menos para o tipo de crimes que dominam em Chicago.

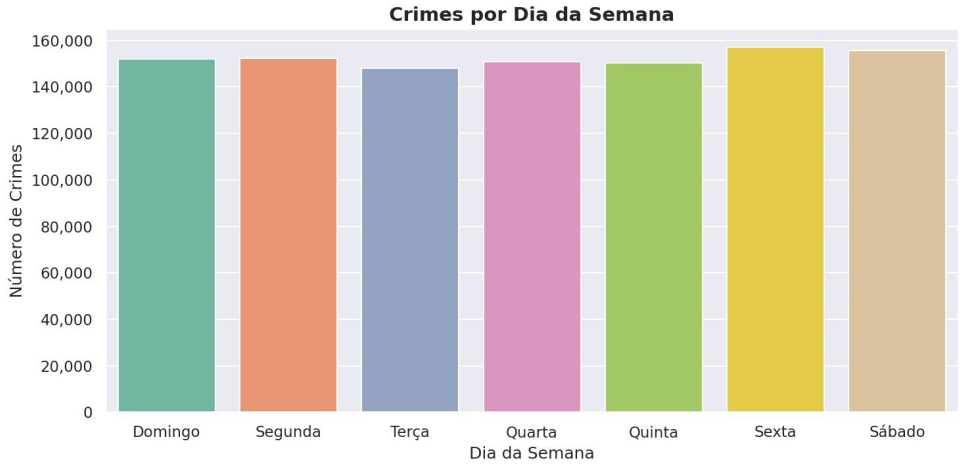


Figura 4 — Crimes por dia da semana

Quanto ao dia da semana, a distribuição é surpreendentemente uniforme. Todos os dias registam entre 148.000 e 158.000 crimes no total do período — a diferença entre Sexta-feira (o dia com mais ocorrências) e Terça-feira (o com menos) é de cerca de 10.000 registos em cinco anos. Não há um dia que se destaque claramente.

4.3 Roubo domina, mas as armas preocupam por razões diferentes

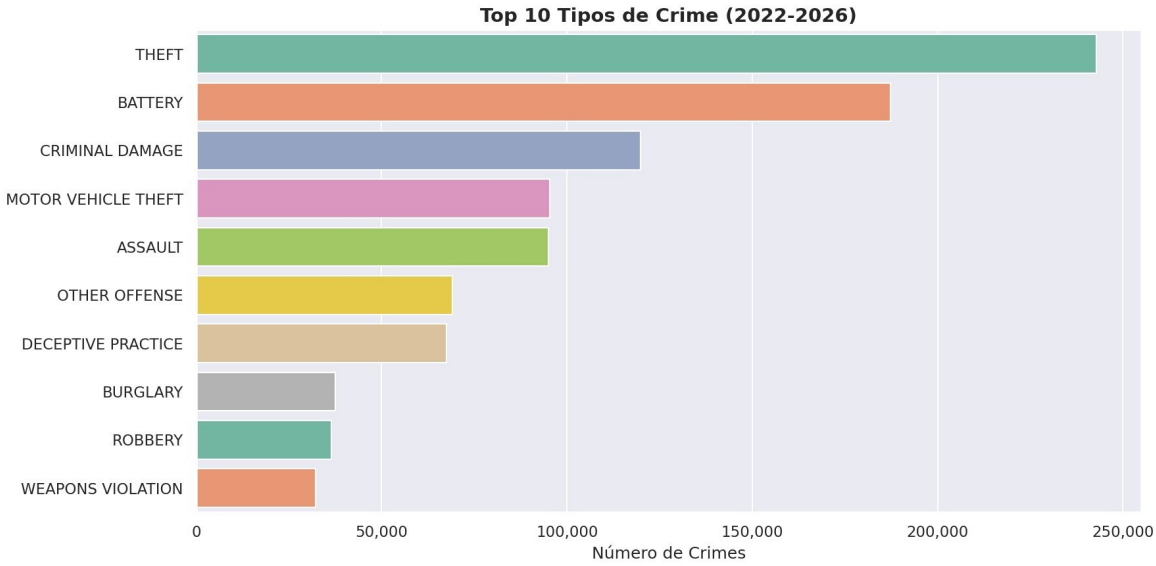


Figura 5 — Top 10 tipos de crime (2022–2026)

THEFT lidera de forma destacada com cerca de 245.000 ocorrências no período total, seguido de BATTERY com aproximadamente 185.000. Os crimes contra a propriedade dominam o ranking, o que é típico de criminalidade urbana de grande escala.

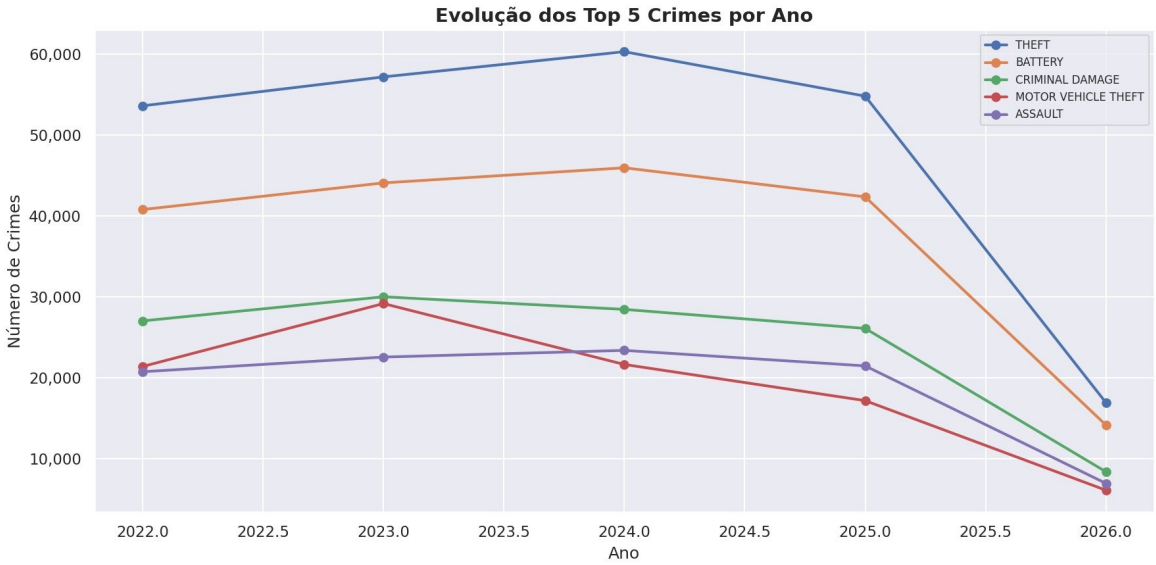


Figura 6 — Evolução dos 5 tipos de crime mais frequentes por ano

A evolução dos cinco tipos mais frequentes mostra que todos atingiram o pico em 2023 ou 2024 e apresentam uma tendência de descida em 2025. THEFT manteve-se consistentemente como o crime mais frequente em todos os anos.

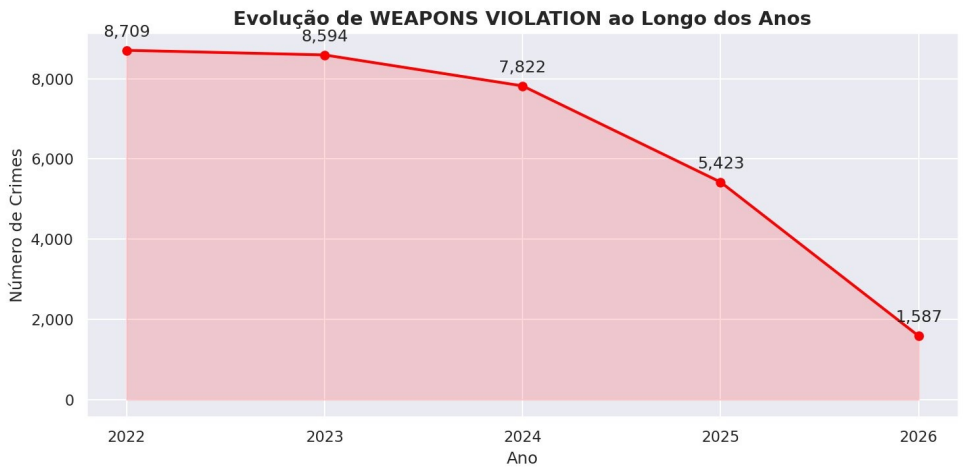


Figura 7 — Evolução de WEAPONS VIOLATION (2022–2026)

WEAPONS VIOLATION merece atenção separada. Em 2022 foram registadas 8.709 ocorrências; em 2023 manteve-se estável (8.594); mas a partir de 2024 a descida acelerou para 7.822, depois 5.423 em 2025 e apenas 1.587 nos primeiros meses de 2026. Uma queda desta magnitude merece ser estudada — pode refletir mudanças legislativas no estado do Illinois ou alterações nas práticas de registo.

4.4 O território não é uniforme

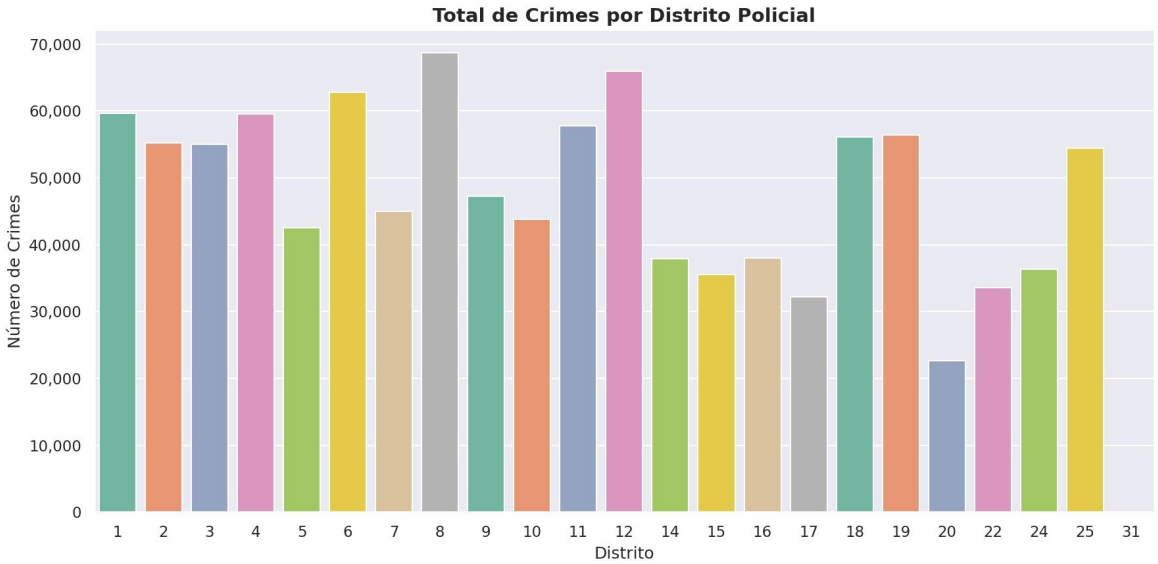


Figura 8 — Total de crimes por distrito policial

O Distrito 8 concentra o maior número de crimes no período (quase 70.000), seguido dos Distritos 12 e 6. Há distritos com menos de 35.000 ocorrências no mesmo período. Esta disparidade tem implicações directas para a alocação de recursos.

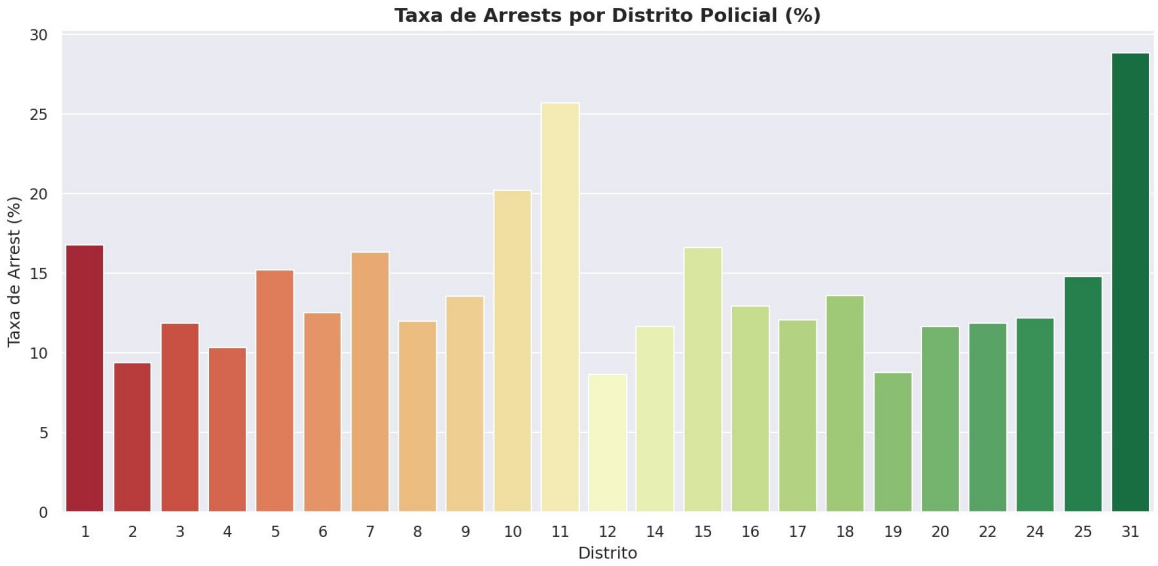


Figura 9 — Taxa de detenções por distrito policial (%)

A taxa de detenções por distrito (número de crimes que resultaram em prisão, como percentagem do total) varia entre menos de 9% (Distrito 12) e cerca de 29% (Distrito 31). Esta diferença pode refletir tanto a tipologia dos crimes em cada zona como a intensidade do policiamento — os dois efeitos são difíceis de separar com estes dados.

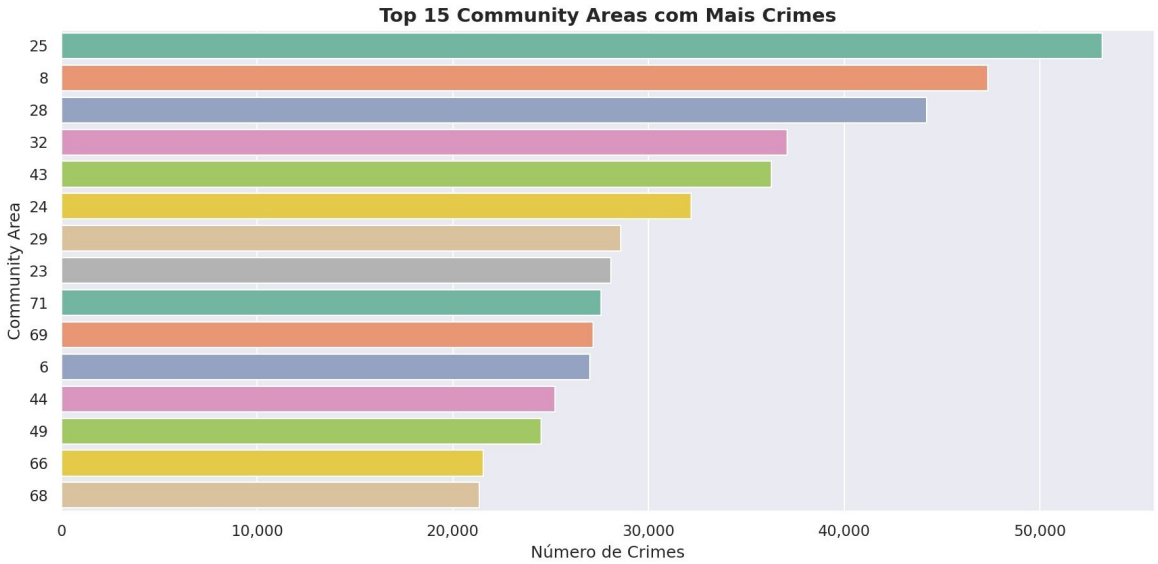


Figura 10 — Top 15 community areas com mais crimes

Ao nível das community areas, a área 25 (Austin) regista mais crimes com cerca de 52.000 ocorrências, seguida pela área 8 (Near North Side) com aproximadamente 47.000. Estes dois bairros têm perfis de criminalidade muito diferentes: Austin tem mais crimes violentos, Near North Side tem um volume elevado de furtos associado à atividade comercial e turística.

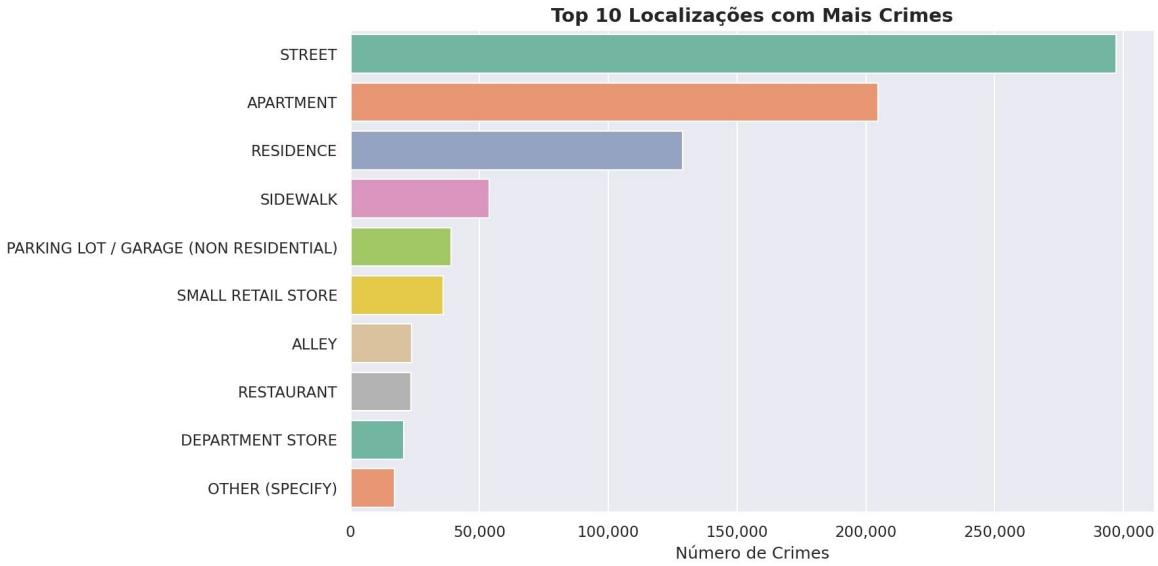


Figura 11 — Top 10 localizações com mais crimes

Quanto ao tipo de espaço onde os crimes ocorrem, a rua (STREET) domina de forma clara com cerca de 300.000 ocorrências, seguida pelo APARTMENT (200.000) e RESIDENCE (130.000). Os espaços públicos são o palco principal da criminalidade em Chicago.

4.5 Crimes domésticos: uma proporção estável

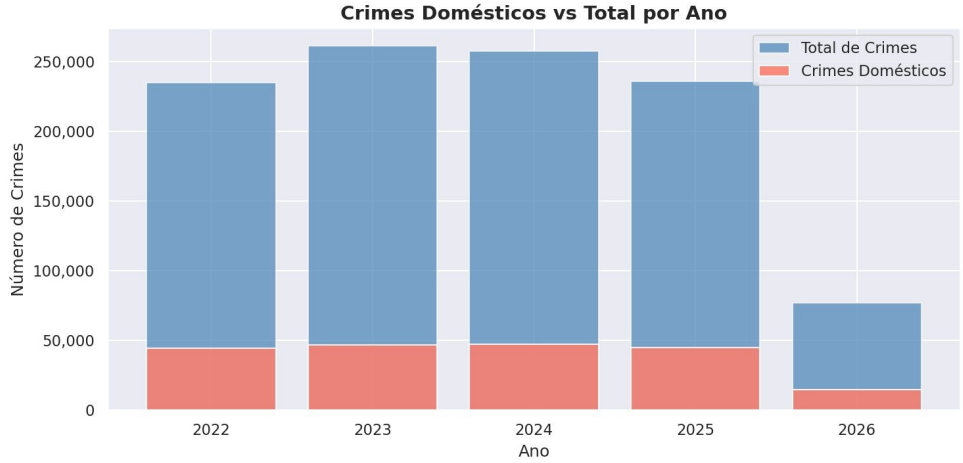


Figura 12 — Crimes domésticos versus total de crimes por ano

Os crimes domésticos representam entre 18% e 20% do total em cada ano — cerca de 45.000 ocorrências anuais. O que é notável é que esta proporção se manteve estável mesmo com as variações no total de crimes. Não respondeu à descida de 2025. É uma dimensão da criminalidade que parece relativamente independente dos outros fatores que afetam o volume global.

4.6 Sazonalidade: Março e Abril surpreendem

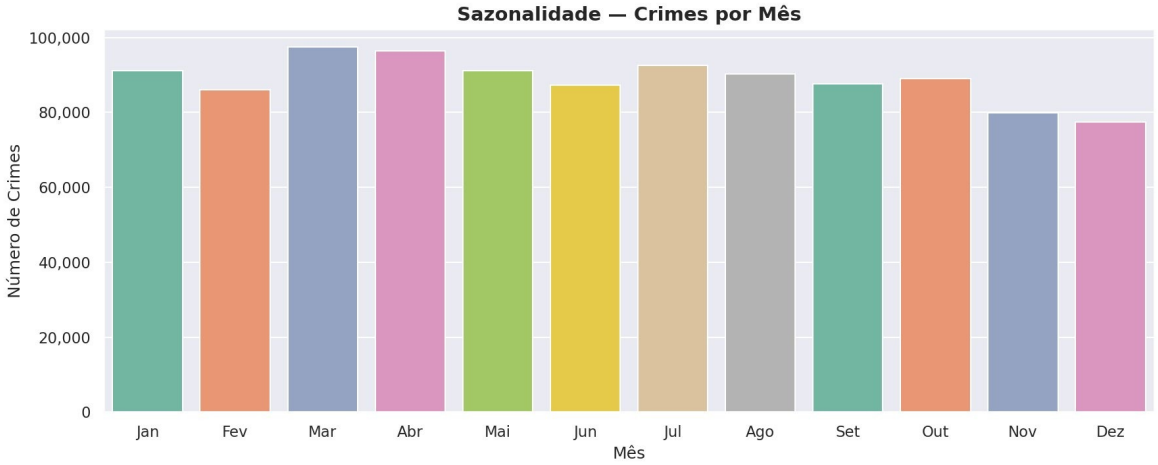


Figura 13 — Crimes por mês (total do período 2022–2026)

A expectativa seria que o verão concentrasse mais crimes — mais calor, mais atividade nas ruas. Os dados mostram outra coisa: Março e Abril são os meses com mais ocorrências, e Novembro e Dezembro os mais baixos. Uma hipótese é que os invernos rigorosos de Chicago reduzam a atividade de rua de forma mais acentuada do que o previsto. Outra é que os crimes de interior (domésticos, fraudes) não diminuam no inverno e que a descida nos meses frios seja explicada pelos crimes de rua.

4.7 Cruzamento: tipo de crime por hora do dia

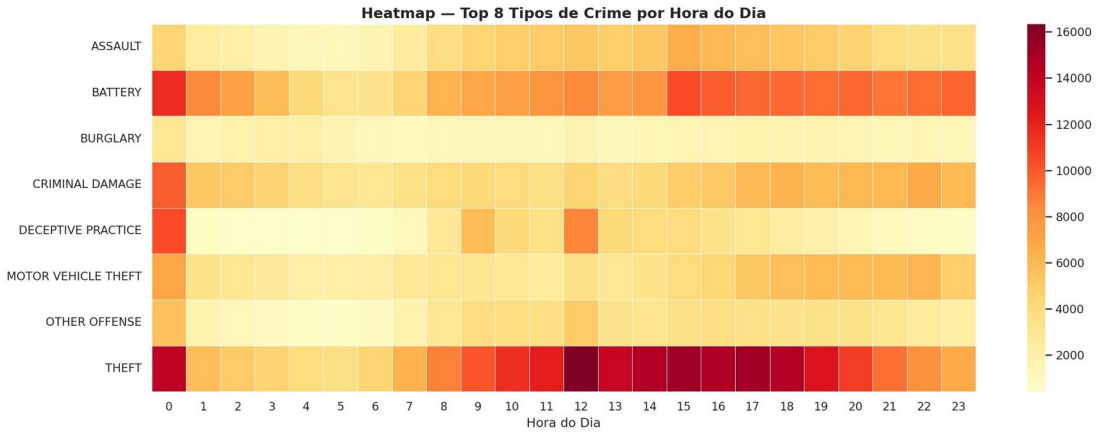


Figura 14 — Heatmap de tipo de crime por hora do dia (top 8 tipos)

O heatmap cruza duas dimensões num único gráfico e revela padrões que as análises individuais não mostram. THEFT concentra-se claramente nas horas de maior atividade comercial — o pico mais escuro é ao meio-dia, mas mantém valores elevados entre as 9h e as 18h. BATTERY tem distribuição mais uniforme, com ligeiro aumento nas horas noturnas. DECEPTIVE PRACTICE tem picos ao meio-dia e às 12h, o que sugere ocorrências em contexto de trabalho ou transações comerciais.

5. Pipeline de Atualização Incremental

Para além da carga inicial, foi desenvolvido um mecanismo de atualização incremental (update_pipeline.py) que orquestra três scripts em sequência: ingestão apenas dos registos com data posterior à última execução (guardando a referência em last_update.txt),

processamento Silver apenas dos novos dados com modo append, e recálculo das métricas Gold para o ano corrente.

O comportamento mais relevante é a inteligência perante a ausência de novos dados: se a API não tiver registos mais recentes que a última execução, o pipeline termina sem executar os passos seguintes. Evita processamento desnecessário e seria viável em produção com execução periódica via cron.

6. Conclusão

O que ficou mais claro neste projeto não foi técnico — foi o quanto os dados contrariaram as expectativas. A criminalidade é maioritariamente diurna, não noturna. Março e Abril têm mais crimes do que julho. A variação entre dias da semana é quase irrelevante. Estes padrões só se tornam visíveis com um volume de dados desta escala, tratado de forma sistemática.

Do ponto de vista técnico, a decisão mais importante foi separar ingestão, limpeza e análise em camadas independentes. Qualquer erro na Silver não contamina o Bronze. Qualquer mudança nos critérios de análise pode ser aplicada recalculando apenas a Gold. A Medallion Architecture não é burocracia — é a razão pela qual o pipeline foi possível de desenvolver e corrigir de forma iterativa.

O Parquet com compressão Snappy e o particionamento por ano mostraram-se igualmente acertados: a diferença de desempenho face ao JSON original é considerável quando as consultas leem apenas uma ou duas partições em vez do dataset completo.

O dataset de Chicago é suficientemente rico para alimentar análises muito mais profundas do que as apresentadas aqui — correlações geográficas com dados socioeconômicos, modelos preditivos por zona, análise de clustering por padrão temporal. O pipeline está construído para suportar esse tipo de extensão sem grandes alterações de arquitetura.